

Grundbegriffe

Die Mengen *aller* Teilmengen von Q heißt **Potenzmenge** von Q , kurz $\wp(Q)$

Die Potenzmenge von $M = \{a, b, c\}$ ist

$$\wp(M) = \{\emptyset, \{a\}, \{b\}, \{c\}, \{a, b\}, \{a, c\}, \{b, c\}, \{a, b, c\}\}$$

$$A = \{a, b, c\}$$

$$A^* = \{\epsilon, \underbrace{a, b, c}_{A^0}, \underbrace{aa, ab, ac, ba, bb, bc, ca, cb, cc}_{A^1}, \underbrace{aaa, \dots}_{A^2}, \dots\}$$

$$A^+ = \{a, b, c, aa, ab, ac, ba, bb, bc, ca, cb, cc, aaa, \dots\}$$

Die gesamte Wortmenge über A setzt sich dann aus den Wörtern dieser unendlich vielen disjunkten Teilmengen A^i zusammen:

$$A^* = \bigcup_{i \in \mathbb{N}} A^i \quad A^+ = A^* \setminus \{\epsilon\}$$

Definition 1.5:

Zwei Mengen M_1 und M_2 heißen *gleichmächtig*, wenn es eine *bijektive* Abbildung von M_1 auf M_2 gibt.

Ist eine der beiden Mengen die der natürlichen Zahlen \mathbb{N} , so ist M eine **abzählbar unendliche Menge**, kurz: „ M ist abzählbar unendlich“.

Speziell für $M = \mathbb{N}$ ist offensichtlich, dass die Menge der natürlichen Zahlen \mathbb{N} eine **abzählbar unendliche Menge** ist. Im Gegensatz dazu ist die Menge der reellen Zahlen \mathbb{R} *überabzählbar* unendlich. Es gibt also (sehr viel) mehr reelle Zahlen als natürliche.

Sprache

Sei A ein Alphabet. Jede Teilmenge $L \subseteq A^*$ heißt **Sprache** über A .

Gehört ein Wort $w \in A^*$ zur Sprache $L \subseteq A^*$?

Sprachen sind Wortmengen und besitzen höchstens abzählbar unendliche viele Elemente.

L sei die Sprache über $A = \{a\}$, die aus einer primzahligen Anzahl von a 's bestehen. Geben Sie eine mathematische Notation dafür an.

$$L = \{a^p \mid p \text{ ist Primzahl}\}, \quad L = \{w \mid w \text{ hat die Form } a(a,b)^*b \text{ oder } b(a,b)^*b(a,b)^*b\}$$

Parsing: Für jedes Wort aus der zugehörigen Wortmenge T^* muss entschieden werden können, ob entweder $w \in L(G)$ oder $w \notin L(G)$ gilt. In der Informatik (Compilerbau) spricht man von **Parsing**.

Beispiel 4.4:

Die Potenzmenge von $M = \{a, b, c\}$ ist

$$\wp(M) = \{\emptyset, \{a\}, \{b\}, \{c\}, \{a, b\}, \{a, c\}, \{b, c\}, \{a, b, c\}\}.$$

Für eine endliche Menge M besitzt $\wp(M)$ genau $2^{|M|}$ Elemente. In Beispiel 4.4 sind das gerade $2^{|M|} = 2^3 = 8$.

Formale Grammatik

Zur Definition einer natürlichen Sprachen benötigen wir eine formale Grammatik.

Definition 2.1:

Eine (formale) **Grammatik** G ist ein 4-Tupel $G = (N, T, P, s)$ mit folgenden Eigenschaften:

$N \dots$ Menge der **Nichtterminale** (grammatikalische Variablen)

$T \dots$ Menge der **Terminale** (Alphabetzeichen)

N, T sind nichtleere, endliche und disjunkte Mengen, d.h. $N \cap T = \emptyset$.

$P \dots$ endliche Menge von **Regeln** oder **Produktionen**

$$P = \{\alpha \rightarrow \beta \mid \alpha \in (N \cup T)^* \setminus T^* \text{ und } \beta \in (N \cup T)^*\}$$

$s \dots$ **Start-** oder **Satz-** oder **Spitzensymbol**, mit $s \in N$.

Definition 2.4:

Die durch G definierte (oder auch erzeugte oder erzeugbare) Sprache $L(G)$ ist

$$L(G) = \{w \mid w \in T^* \text{ und } s \Rightarrow_G^* w\}.$$

Definition 2.7:

Zwei Grammatiken G_1 und G_2 heißen *äquivalent*, geschrieben: $G_1 \equiv G_2$, wenn die zugehörigen erzeugbaren Sprachen übereinstimmen, d.h., wenn $L(G_1) = L(G_2)$.

Chomsky-Hierarchie

Typ	Bezeichnung	Regelgestalt	Beispiele
0	unbeschränkt	keine Einschränkung	$\alpha A \beta B \rightarrow \alpha \alpha \gamma \beta \beta$
1	kontextsensitiv	wie Typ 0 und zusätzlich: <i>längenmonotone</i> Regeln, d. h. $ \alpha \leq \beta $; Ausnahme: $s \rightarrow \varepsilon$ darf vorkommen, wenn s in keiner Regel auf der rechten Seite steht	$ w_1 \leq w_2 $ $\alpha A \beta \rightarrow \alpha \gamma \beta$ $S \rightarrow \varepsilon$
2	kontextfrei	wie Typ 1 und zusätzlich: $\alpha \in N$; Ausnahme: Regeln der Form $\alpha \rightarrow \varepsilon$ sind erlaubt	$ w_1 = 1$ $A \rightarrow a A B a$
3	regulär	wie Typ 2 und zusätzlich: Neben Regeln der Form $\alpha \rightarrow x$ gibt es entweder <i>nur</i> linkslineare, d. h. $\alpha \rightarrow A x$, oder <i>nur</i> rechtslineare, d. h. $\alpha \rightarrow x A$, mit $x \in T$ und $A \in N$	$A \rightarrow a B$ oder $A \rightarrow B a$

Kontextsensitive Sprache $L(G) = \{a^n b^n c^n \mid n \in \mathbb{N}, n \geq 1\}$

$$\mathcal{L}_{\text{LBTM}} = \mathcal{L}_{\text{Typ1}}$$

Kontextfreie Sprache $L(G) = \{a^n b^n \mid n \in \mathbb{N}, n \geq 1\}$

$$\mathcal{L}_{\text{kfs}} = \mathcal{L}_{\text{NKA}} \quad \mathcal{L}_{\text{DKA}} \subseteq \mathcal{L}_{\text{NKA}}$$

Reguläre Sprache $L(G) = \{a^n \mid n \in \mathbb{N}, n \geq 1\}$

$$\mathcal{L}_{\text{NEA}_e} \equiv \mathcal{L}_{\text{DEA}} \equiv \mathcal{L}_{\text{rG}}$$


Reguläre Sprache $L(G) = \{w \mid w \in \{a, b\}^* \text{ beginnt oder endet mit } a\}$

Regulärer Ausdruck = $a(a+b)^* + (a+b)^* a$



Zusammenfassung

Die von Chomsky definierten Sprachklassen bilden eine Hierarchie:



$$\mathcal{L}_{endlich} \subset \mathcal{L}_{Typ3} \subset \mathcal{L}_{Typ2} \subset \mathcal{L}_{Typ1} \subset \mathcal{L}_{Typ0}$$

ε -Sonderregelungen

Die ε -Regeln verstoßen gegen die **Längenmonotonie**. Bsp. $A \rightarrow \varepsilon$

Regel: $|\alpha| \leq |\beta|$ Aber $|\alpha| > 0$ & $|\beta| = |\varepsilon| = 0$ Somit $|\alpha| > |\beta|$

Die Verwendung solcher ε -Regeln macht die Formulierung einer Grammatik bequemer.

Zu jeder ε -freien Grammatik $_{Typ1,2,3}$ gibt es eine äquivalente Grammatik $'_{Typ1,2,3}$
 $L(G') = L(G) \cup \{\varepsilon\}$

Grammatiktransformation für **ksG** und **kfG**:

- Wähle ein noch nicht in N vorhandenes Nichtterminal s als Spitzensymbol von G .
- Ergänze die Regeln $S' \rightarrow s$ und $s' \rightarrow \varepsilon$

Aus G entsteht die Grammatik

$$G' = (N \cup \{s'\}, T, P \cup \{s' \rightarrow s | \varepsilon\}, s')$$

Bsp. $G = (\{K, H\}, \{i, j, l, r\}, \{K \rightarrow iHj, H \rightarrow lK|r\}, K)$

$$G' = (\{K, H, Q\}, \{i, j, l, r\}, \{Q \rightarrow K | \varepsilon, K \rightarrow iHj, H \rightarrow lk|r\}, Q)$$

a) b)

Grammatiktransformation für **reguläre Grammatiken**:

- Wähle ein noch nicht in N vorhandenes Nichtterminal s' als Spitzensymbol von G' .
- Ergänze für alle Regeln $s \rightarrow \beta$ in P die Regeln $s' \rightarrow \beta$ sowie $s' \rightarrow \varepsilon$.

Bsp. $G = (\{S, H\}, \{a, b\}, \{S \rightarrow aS | aH, H \rightarrow b\}, S)$

$$G' = (\{S, H, Q\}, \{a, b\}, \{Q \rightarrow aS | aH | \varepsilon, S \rightarrow aS | aH, H \rightarrow b\}, Q)$$

a) b)

ε -Freiheit herstellen

Zu jeder Grammatik_{Typ1,2,3} gibt es eine äquivalente Grammatik'_{Typ1,2,3} ohne ε -Regeln. (ggf. bis auf $S' \rightarrow \varepsilon$).

- Zunächst werden alle Nichtterminale gesucht, die zu ε abgeleitet werden können, ohne dass ein neuer Nichtterminal entsteht. $N_\varepsilon = \{A_i\}$ für alle $A_i \rightarrow \varepsilon$
- Entferne ε und füge in jeder Regel das Nichtterminal hinzu.

Bsp. $G = (\{S, B, T\}, \{a, b\}, P, S)$
 $P = \{S \rightarrow abS \mid aS \mid aB,$
 $\quad B \rightarrow aB \mid T,$
 $\quad T \rightarrow abT \mid \varepsilon\}$
 $N_\varepsilon = \{B, T\}$
 $P' = \{S \rightarrow abS \mid aS \mid aB \mid a,$
 $\quad B \rightarrow aB \mid T \mid a,$
 $\quad T \rightarrow abT \mid ab\}$

a) Mit B, T kann zu ε Abgeleitet werden.

b) Nun wird in jeder Regel, wo ein **Nichtterminal + Terminal** aus a) steht, eine neue Regel mit dem Nichtterminal hinzugefügt. ε wird entfernt.

Das Wortproblem

Das Wortproblem ist für Typ-1,2,3 Sprachen entscheidbar, jedoch nicht für Sprachen vom Typ 0.

Wenn die betrachtete Satzform β eine Länge besitzt, die größer als $n = |w|$ ist, wird diese Satzform nicht in S_{i+1} übernommen. Aufgrund der für ksG geforderten **Längenmonotonie** wäre sie eine (für die Ableitung von w) aussichtslose Kandidatin.

Bsp. $G = (\{A, B\}, \{a, b, c\}, \{A \rightarrow aABc \mid aBc, cb \rightarrow Bc, aB \rightarrow ab, bB \rightarrow bb\}, A)$
 $\{S_0\} = \{A\}$
 $\{S_1\} = \{A, aABc, aBc\}$
 $\{S_2\} = \{A, aABc, aBc, aaABcBc, aaBcBc, abbc\}$, da $|aaABcBc| = 7 > |w|$ und $abbc \neq w$
 $\{S_3\} = \{A, aABc, aBc, aaBcBc, aabcBc, aaBBcc\}$
 $\{S_4\} = \{A, aABc, aBc, aaBcBc, aabcBc, aaBBcc, aabBcc\}$
 $\{S_5\} = \{A, aABc, aBc, aaBcBc, aabcBc, aaBBcc, aabBcc, aabbcc\}$ und Stopp
 da $aabbcc = w$

Beweis:

Die Längenmonotonie der Grammatik ist die Voraussetzung dafür, dass das oben beschriebene Verfahren im Allgemeinen terminiert. Chomsky-Typ-0-Grammatiken müssen nicht längenmonoton sein.

Mehrdeutigkeit kontextfreier Grammatiken

Eine KfG ist *mehrdeutig*, wenn es ein Wort in $L(G)$ gibt, das (mindestens) zwei Linksableitungen besitzt. Andernfalls ist die Grammatik eindeutig.

Eine kfS ist eindeutig, wenn es (mindestens) ein eindeutige kfG G , mit $L = L(G)$, gibt. Ansonsten ist L (inhärent) mehrdeutig.

Bsp. Für das Wort abc gibt es zwei Linksableitungen: $S \rightarrow aB \rightarrow abc$ und $S \rightarrow Ac \rightarrow abc$.

Äquivalenz

Zwei Grammatiken G_1 und G_2 heißen *äquivalent*, geschrieben $G_1 \cong G_2$, wenn die zugehörigen erzeugbaren Sprachen übereinstimmen, d.h., wenn $L(G_1) = L(G_2)$.

Reguläre Sprachen

Deterministischer endlicher Automat (DEA, EA)

Endliche Automaten definieren reguläre Sprachen.

Ein **deterministischer endlicher Automat**, kurz: DEA (auch EA) ist ein Quintupel

$M = (Q, \Sigma, \delta, q_0, E)$ welche **reguläre Sprachen definiert**.

$Q \dots$ endliche Menge der Zustände

$\Sigma \dots$ Eingabealphabet, $Q \cap \Sigma = \emptyset$

$\delta \dots$ Überföhrungsfunktion (totale Funktion), $Q \times \Sigma \rightarrow Q$


$q_0 \dots$ Startzustand, $q_0 \in Q$

$E \dots$ endliche (nichtleere) Menge der Endzustände, $E \subseteq Q$

$\delta(q_i, a)$ $q_i \in Q$ und $a \in \Sigma$, definiert den Folgezustand

$\hat{\delta}(q, \varepsilon) = q$ ← Der Automat drückt aus, dass er für $w = \varepsilon$ in Zustand q stoppt

$\hat{\delta}(q, aw) = \hat{\delta}(\delta(q, a), w)$ Nach dem Zustandswechsel von q zu $\delta(q, a)$ wird mit dem Restwort w fortgesetzt.




Definition 4.4:

Unter Verwendung von $\hat{\delta}$ kann die von einem DEA akzeptierte Sprache wie folgt beschrieben werden:

$$L(M) = \{w \mid w \in \Sigma^* \text{ und } \hat{\delta}(q_0, w) = q_e \text{ und } q_e \in E\}$$

Beispiel deterministischer endlicher Automat (DEA)

DEA $M = (Q, \Sigma, \delta, q_0, E) = (\{q_0, q_1, q_2, q_3\}, \{a, b\}, \delta, q_0, \{q_0, q_1, q_2\})$



δ	a	b
q_0	q_0	q_1
q_1	q_0	q_2
q_2	q_0	q_3
q_3	q_3	q_3

$L(M)$ ist die Menge aller Wörter über $\{a, b\}^*$, die höchstens zwei b 'sam Stück enthalten.
(D.h. genau 0,1 oder 2 b 's)


$G = (N, T, P, s) = (\{q_0, q_1, q_2\}, \{a, b\}, P, q_0)$

$P = \{q_0 \rightarrow a \mid b \mid b \mid q_1 \mid a \mid q_0 \mid \varepsilon,$

$q_1 \rightarrow a \mid q_0 \mid a \mid b \mid q_2 \mid b,$

$q_2 \rightarrow a \mid a \mid q_0\}$

Auch das leere Wort gehört zur Wortmenge dazu



Nichtdeterministischer endlicher Automat (NEA)

$$M = (Q, \Sigma, \delta, q_0, E)$$

Q ... endliche Menge der Zustände

Σ ... Eingabealphabet, $Q \cap \Sigma = \emptyset$


δ ... Überföhrungsfunktion (totale Funktion), $Q \times \Sigma \rightarrow \wp(Q)$

q_0 ... Startzustand, $q_0 \in Q$


E ... endliche (nichtleere) Menge der Endzustände, $E \subseteq Q$

Beispiel 4.5:

Der NEA $M = (\{q_0, q_1, q_2, q_3, q_4\}, \{a, b\}, \delta, q_0, \{q_2, q_3, q_4\})$ mit



δ	a	b
q_0	$\{q_1, q_4\}$	$\{q_3\}$
q_1	$\{q_1\}$	$\{q_2\}$
q_2	$\{\}$	$\{\}$
q_3	$\{\}$	$\{\}$
q_4	$\{\}$	$\{q_4\}$



akzeptiert die Sprache $L = \{w \mid w = a^n b \text{ oder } w = ab^n, n \geq 0\}$.

Akzeptiert mehr als ein Automat das Eingabewort, so ist die Grammatik mehrdeutig

Linkslinere Grammatik in rechtslinere transformieren

a) Transformation aller Regeln in linkslinere Regeln: $X \rightarrow Ya$ bleiben unverändert.

$X \rightarrow a$ werden ersetzt durch $X \rightarrow Ha$ und $H \rightarrow \varepsilon$.

b) Transformation der vorbereiteten Regeln in rechtslinere: Wähle H als neues Spitzensymbol und streiche die Regel $H \rightarrow \varepsilon$. Ergänze $s \rightarrow \varepsilon$, wobei s das Spitzensymbol der linkslinaren Grammatik ist. Ersetze jede Regel der Form $X \rightarrow Ya$ durch $Y \rightarrow aX$, Falls $\varepsilon \in L(G)$, muss $H \rightarrow \varepsilon$ wieder hinzugefügt werden.

Bsp. $G = (\{A, B, S\}, \{a, b, c\}, P, S)$ $P = \{S \rightarrow Bc \mid Ac, A \rightarrow a \mid Aa, B \rightarrow b \mid Bb\}$

a) $G' = (\{A, B, S, H\}, \{a, b, c\}, P', S)$

$P' = \{S \rightarrow Bc \mid Ac; A \rightarrow Ha \mid Aa; B \rightarrow Hb \mid Bb; H \rightarrow \varepsilon\}$

b) $G'' = \{A, B, S, H\}, \{a, b, c\}, P'', H)$

$P' = \{S \rightarrow Bc \mid Ac; A \rightarrow Ha \mid Aa; B \rightarrow Hb \mid Bb; H \rightarrow \varepsilon\}$

$P'' = \{H \rightarrow aA \mid bB; A \rightarrow cS \mid aA; B \rightarrow cS \mid bB; S \rightarrow \varepsilon\}$

$X \rightarrow Ya$
 $Y \rightarrow aX$

Konstruktion eines NEA aus einer regulären Grammatik

1. ε -Freiheit herstellen (siehe oben)
2. Linkslinare Regeln in rechtslineare Regeln transformieren (siehe letzten Schritt)
3. Allgemeine Konstruktionsprinzip:

Gegeben: reguläre Grammatik $G = (N, T, P, s)$ ohne ε -Regeln

Gesucht: NEA $M = (Q, \Sigma, \delta, q_0, E)$, mit $L(M) = L(G)$

$\Sigma = T$ und $q_0 = s$

$Q = N \cup \{q_x\}$, mit $q_x \notin N$, und δ wie folgt:

Falls $A \rightarrow aB$ in P existiert, so füge $\delta(A, a) \ni B$ in δ hinzu

Falls $B \rightarrow a$ in P existiert, so füge $\delta(B, a) \ni q_x$ in δ hinzu

Für die Menge der Endzustände E des NEA M gilt

$$E = \begin{cases} \{q_0, q_x\}, & \text{wenn } (s \rightarrow \varepsilon) \in P \\ \{q_x\}, & \text{sonst} \end{cases}$$

δ	a	...
A	B	...
B	q_x	...

q_x sind Endzustände, welche hinzugefügt werden.

Bsp. $G = (\{S, A, B\}, \{a, b\}, \{S \rightarrow aA \mid aB \mid a, A \rightarrow b \mid bA, B \rightarrow b \mid aB\}, S)$

$M = (Q, \Sigma, \delta, q_0, E)$


$\Sigma = T = \{a, b\}$

$q_0 = s = S$

$E = \{q_1, q_2, q_3\}$

$Q = \{S, A, B, q_1, q_2, q_3\}$

δ	a	b
S	$\{A, B, q_2\}$	$\{\}$
A	q_0	$\{q_1, A\}$
B	B	q_3
q_1	$\{\}$	$\{\}$
q_2	$\{\}$	$\{\}$
q_3	$\{\}$	$\{\}$



NEA zu einem äquivalenten DEA konstruieren

Jedes Element (also jeder Menge) aus $\wp(Q)$ wird genau ein Zustand z_i zuzuordnen. Dann kann die Überföhrungsfunktion δ' des gesuchten DEA M' aus δ des betrachteten NEA $M = (Q, \Sigma, \delta, q_0, E)$ nach Vorschrift

$\delta'(z, a) = \coprod_{q \in z} \delta(q, a)$ gebildet werden. Die anderen Bestandteile von $M' = (Q', \Sigma', \delta', z_0, E')$ ergeben sich aus

$Q' = \wp(Q)$ nach Umbenennung zu z_i , mit $0 \leq i \leq 2^{|Q|}$


$z'_0 = z_0 = \{q_0\}$

$E' = \{R \mid R \subseteq Q \text{ und } R \cap E \neq \emptyset\}$ nach Umbenennung zu z_i

Beispiel

Konstruktion eines äquivalenten DEA $M' = (Q', \Sigma', \delta', z_0, E')$ aus einem NEA

$M = (\{q_0, q_1, q_2\}, \{0, 1\}, \delta, q_0, \{q_2\})$ mit



$$\wp(Q) = \left\{ \underbrace{\{q_0\}}_{z_0}, \underbrace{\{q_1\}}_{z_1}, \underbrace{\{q_2\}}_{z_2}, \underbrace{\{q_0, q_1\}}_{z_3}, \underbrace{\{q_0, q_2\}}_{z_4}, \underbrace{\{q_1, q_2\}}_{z_5}, \underbrace{\{q_0, q_1, q_2\}}_{z_6}, \underbrace{\emptyset}_{z_7} \right\}$$

$$\begin{aligned} \delta'(z_3, 0) &= \delta'(\{q_0, q_1\}, 0) = \delta(q_0, 0) \cup \delta(q_1, 0) \\ &= \{q_0, q_1\} \cup \{q_2\} = \{q_0, q_1, q_2\} \\ &= z_6 \end{aligned}$$

δ	0	1
q_0	$\{q_0, q_1\}$	q_0
q_1	q_2	\emptyset
q_2	\emptyset	\emptyset




δ'	0	1	δ'
q_0	$\{q_0, q_1\}$	q_0	z_0
$\{q_0, q_1\}$	$\{q_0, q_1, q_2\}$	q_0	z_3
$\{q_0, q_1, q_2\}$	$\{q_0, q_1, q_2\}$	q_0	z_6

(Der Folgezustand von)

$$\delta'(z_0, 0) = \delta'(\{q_0\}, 0) = \delta(q_0, 0) = \{q_0, q_1\} = z_3$$




Wenn sich hier ein Endzustand befindet, wird der neue auch Endzustand

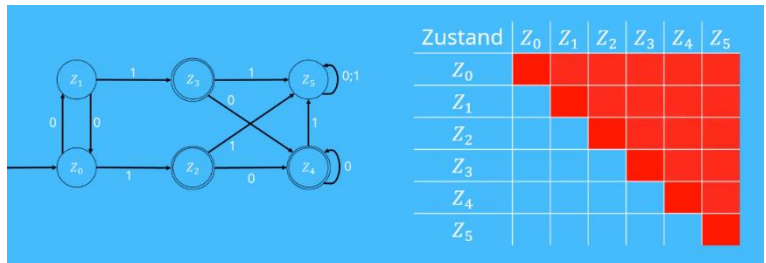


Minimalautomat


Da Zustände nicht mit sich selbst überprüft werden müssen, können wir die **Diagonale der Tabelle** komplett **streichen**.



Außerdem werden die **Paare nur in eine Richtung betrachtet**, wir müssen die Paare (z_1, z_2) und (z_2, z_1) also nicht als einzelne Paare sehen und können damit die **obere Hälfte der Tabelle über der Diagonalen** (in der Abbildung rot markiert) **streichen**.

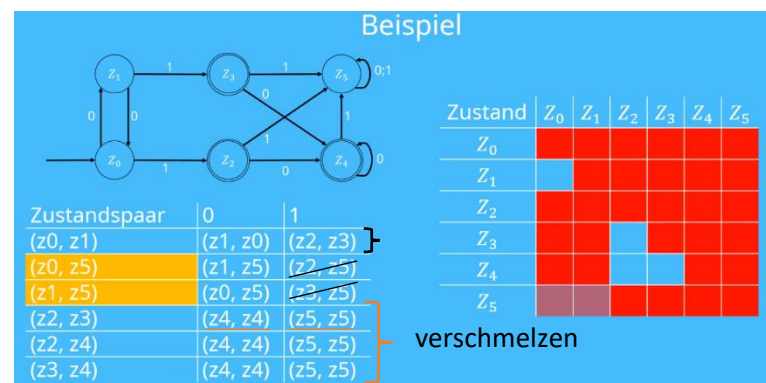


Markiere nun alle Paare, wenn genau **einer der beiden Zustände**, also entweder z oder z , ein Endzustand ist.



Wir testen jetzt für jedes Zustandspaar die Folgezustände bei der Eingabe der Zeichen 0 und 1. In der ersten Zeile wird Beispielsweise der Zustand z_0 bei Eingabe einer 0 zu z_1 , während der Zustand z_1 zu z_0 wird.


Wir suchen uns nun die Zustandspaare, die bei einer



Eingabe ein Zustandspaar ergeben, das bereits gestrichen ist. Ein Beispiel ist das Zustandspaar $(z_0, z_5) \rightarrow z_2, z_5$. Finden wir **ein** paar, so wird das Zustandspaar gestrichen.

Wenn beim Überprüfen eines Zustandspaares ein Zustand (z_i, z_i) entsteht, wird dieser nicht gestrichen.

Die **übrig gebliebenen Paare** können wir nun **kombinieren**.



Reguläre Ausdrücke

Die Idee besteht darin, zu deren Definition nur ganz wenige Basismengen und insgesamt nur **drei Mengenoperationen** zu verwenden. Durch deren wiederholte und kombinierte Anwendung kann jede beliebige reguläre Menge (Sprache) erzeugt werden. Die **einzigsten Basismengen** sind:

- \emptyset Die leere Menge, die also kein einziges Wort enthält, nicht einmal das leere Wort.
- $\{\epsilon\}$ Die Menge, die nur das leere Wort ϵ enthält.
- $\{a\}$ Alle Einermengen, die nur jeweils genau ein ein-zeichiges Wort, das aus dem zugehörigen Alphabet Zeichen besteht, enthalten.

Die so definierten Basismengen sind reguläre Mengen. Durch Anwendung der im Folgenden angegebenen Operationen – und **nur durch diese** – entstehen weitere reguläre Mengen.

- \cup Vereinigung: $A \cup B = \{w \mid w \in A \text{ oder } w \in B\}$
- \circ Konkatenation: $A \circ B = \{w = w_1 \circ w_2 = w_1 w_2 \mid w_1 \in A \text{ und } w_2 \in B\}$
- $*$ Kleene-Stern: $A^* = A^0 \cup A^1 \cup \dots \cup A^i \cup \dots$

$$\{a\} \circ \{b\} = \{a\}\{b\} = \{ab\} \text{ aber } \{a\} \cup \{b\} = \{a, b\}$$
$$\{a, b\}^* = \{\epsilon, a, b, ab, ba, aa, bb, aaa, aab, aba, baa, abb, \dots\}$$

Definition 4.8:

Reguläre Ausdrücke über einem Alphabet Σ sind wie folgt induktiv definiert:

- a) \emptyset , ϵ und a , für jedes $a \in \Sigma$, sind reguläre Ausdrücke über Σ und bezeichnen die Mengen \emptyset , $\{\epsilon\}$ bzw. $\{a\}$.
- b) Seien u und v reguläre Ausdrücke über Σ und $L(u)$ bzw. $L(v)$ die zugehörigen Sprachen. Dann sind auch
 - 1) $(u + v) = L(u) \cup L(v)$,
 - 2) $(u \cdot v) = L(u) \circ L(v)$ und
 - 3) $(u^*) = L(u)^*$ sowie $(v^*) = L(v)^*$reguläre Ausdrücke über Σ .
- c) Nur die mit diesen Regeln erzeugten Ausdrücke sind reguläre Ausdrücke über Σ .

Σ =Eingabealphabet

Zur Abkürzung schreibt man auch gern $x^+ = xx^*$ und $x^n = \underbrace{x \dots x}_{n\text{-mal}}$.

Beispiel 4.10:

Die oben betrachtete Sprache $((\{a\}((\{a\} \cup \{b\})^*))(\{b\}\{b\}))(\{a\} \cup \{b\})^*$ kann mit folgendem regulären Ausdruck

$$(((a * ((a + b)^*)) * (b * b)) * ((a + b)^*))$$

Da **Vereinigung** und **Konkatenation** (\cup und $*$) und assoziative Operationen sind, dürfen die betreffenden Klammern einfach weggelassen werden.


$$a(a + b)^*bb(a + b)^*$$

Zusammenfassung

u, v und w seien reguläre Ausdrücke.

- $\emptyset u = u \emptyset = \emptyset$ – mit Erinnerung an die Multiplikation mit 0. Sehr wichtig!
- $\varepsilon u = u \varepsilon = u$ – mit Erinnerung an die Multiplikation mit 1.
- $\emptyset^* = \varepsilon$
- $\varepsilon^* = \varepsilon$
- $u + v = v + u$ – Erinnerung an die Kommutativität der Addition.
- $u + \emptyset = u$ – Erinnerung an die Addition von 0.
- $u + u = u$ – verstößt gegen die Analogie.
- $(u^*)^* = u^*$
- $u(v + w) = uv + uw$ – mit Erinnerung an die Distributivität.
- $(uv)^* u = u(vu)^*$
- $(u + v)^* = (u^* + v^*)^*$

Reguläre Sprache $L(G) = \{w \mid w \in \{a, b\}^* \text{ beginnt oder endet mit } a\}$
 Regulärer Ausdruck $= a(a + b)^* + (a + b)^* a$



Reguläre Ausdrücke und endliche Automaten

Eine Sprache L wird von einem DEA M genau dann akzeptiert, wenn L durch einen regulären Ausdruck R über dem zu M gehörenden Eingabealphabet beschrieben werden kann.

$$L(M) = L(R) = L$$

Zu jedem $NEA_\varepsilon M$ gibt es einen äquivalenten $NEA_\varepsilon M'$ mit genau einem Endzustand

$$\mathcal{L}_{NEA_\varepsilon} \equiv \mathcal{L}_{DEA} \equiv \mathcal{L}_{rG}$$

